BAB 1
PENDAHULUAN

1.1 Latar Belakang

Pemanfaatan *Large Language Model* (LLM) pada aplikasi layanan pelanggan memungkinkan sistem menghasilkan respons terhadap pertanyaan pengguna dalam bahasa alami. Pada sistem yang menggunakan *Retrieval-Augmented Generation* (RAG), penyusunan respons juga melibatkan pengambilan informasi dari basis pengetahuan sebagai konteks bagi model. Pemrosesan yang dilakukan kembali untuk pertanyaan dengan jawaban yang sama dapat menambah konsumsi token dan waktu tunggu. Salah satu pendekatan untuk mengurangi pemrosesan berulang tersebut adalah *semantic response caching*, yaitu penyimpanan dan penggunaan ulang respons berdasarkan kemiripan makna pertanyaan. GPTCache merupakan salah satu arsitektur yang menyediakan mekanisme ini untuk mendukung efisiensi aplikasi berbasis LLM (Bang, 2023).

Penggunaan ulang respons memerlukan keputusan yang lebih cermat daripada sekadar menemukan pertanyaan dengan makna yang berdekatan. Dalam penelitian ini, objek yang dikaji adalah simulasi layanan pelanggan pembayaran digital berbahasa Indonesia, khususnya pertanyaan mengenai prosedur dan kebijakan yang jawabannya stabil dalam satu versi basis pengetahuan. Sebagai ilustrasi, pertanyaan "Transfer belum dikonfirmasi, apakah masih bisa dibatalkan?" dan "Transfer sudah berhasil, apakah masih bisa dibatalkan?" memiliki susunan kata serta maksud umum yang berdekatan. Meskipun demikian, perbedaan status transaksi dapat menyebabkan respons yang berlaku bagi kedua pertanyaan tersebut berbeda menurut kebijakan layanan. Ilustrasi ini menunjukkan bahwa kemiripan pertanyaan perlu dibedakan dari validitas penggunaan ulang respons. Kandidat yang tampak mirip, tetapi responsnya tidak sesuai dengan kondisi pertanyaan baru, merupakan contoh *hard negative* dalam pengambilan keputusan *cache*.

Salah satu mekanisme penerimaan respons pada *semantic cache* adalah penggunaan ambang kemiripan statis. Respons kandidat diterima apabila skor kemiripannya memenuhi ambang yang telah ditentukan. Penggunaan satu ambang untuk seluruh pertanyaan menghadapi kompromi antara kesempatan penggunaan ulang dan risiko kesalahan. Ambang yang rendah dapat menerima lebih banyak kandidat, termasuk kandidat yang responsnya tidak valid, sedangkan ambang yang tinggi dapat menolak parafrasa yang sebenarnya dapat menggunakan respons yang sama. Permasalahan ambang statis juga menjadi perhatian dalam vCache, yang mempelajari ambang secara daring untuk setiap pertanyaan tersimpan. Dengan demikian, penyesuaian ambang secara adaptif telah dikaji dalam penelitian sebelumnya dan tidak diperlakukan sebagai kebaruan tersendiri dalam penelitian ini (Schroeder et al., 2026).

Selain kebijakan ambang, kualitas kandidat dipengaruhi oleh mekanisme pencarian yang digunakan. Pencarian semantik berbasis representasi vektor dapat dikombinasikan dengan pencarian leksikal untuk memanfaatkan informasi yang saling melengkapi. Analisis fungsi penggabungan pada *hybrid retrieval* menunjukkan pentingnya cara menggabungkan skor serta penanganan skala kedua sinyal tersebut (Bruch et al., 2023). Berdasarkan landasan ini,

penelitian direncanakan menggunakan kombinasi kemiripan kosinus antarrepresentasi vektor dan BM25 sebagai skor hibrida. Mekanisme pencarian tersebut menjadi fondasi bersama bagi seluruh metode ambang yang dibandingkan. Fokus kontribusi penelitian terletak pada keputusan penerimaan respons setelah satu kandidat dengan skor tertinggi diperoleh, bukan pada pengembangan fungsi pencarian hibrida yang baru.

Perkembangan penelitian *semantic caching* memperlihatkan bahwa keputusan penggunaan ulang dapat dipengaruhi oleh karakteristik yang berbeda. Pendekatan berbasis kategori mengatur kebijakan *cache* menurut kategori beban kerja (Wang et al., 2025). ContextCache menggunakan informasi percakapan untuk menangani kueri multigilir (Yan et al., 2025), sedangkan FreshCache mempertimbangkan risiko keusangan informasi pada RAG berbasis web (Mansoor et al., 2026). Penelitian-penelitian tersebut memberikan konteks bagi perlunya kebijakan penerimaan yang memperhatikan karakteristik permintaan. Namun, ruang kajian penelitian ini dibatasi pada pertanyaan satu giliran dengan jawaban stabil, sehingga perhatian diarahkan pada distribusi skor penggunaan ulang yang tidak valid di sekitar pertanyaan masuk, bukan pada riwayat percakapan atau perubahan informasi dari waktu ke waktu.

Hipotesis yang mendasari penelitian ini adalah bahwa distribusi skor kandidat tidak valid dapat berbeda pada bagian-bagian ruang semantik. Pada sebagian kelompok pertanyaan, kandidat tidak valid mungkin memiliki skor yang mudah dipisahkan dari kandidat valid. Pada kelompok lain, perbedaan negasi, angka, status, atau syarat kebijakan dapat menghasilkan kandidat tidak valid dengan skor yang tinggi. Apabila perbedaan distribusi tersebut dapat diidentifikasi, informasi lokal berpotensi membantu penentuan ambang yang lebih sesuai bagi pertanyaan masuk. Dugaan ini merupakan hipotesis penelitian yang perlu diuji secara empiris, bukan kesimpulan dari eksperimen yang telah dilakukan.

Untuk menguji hipotesis tersebut, penelitian ini mengusulkan penentuan ambang adaptif terhadap kueri berbasis *Local Negative Quantile* (LNQ) pada *hybrid semantic cache*. Pendekatan ini menggunakan bank kalibrasi yang dibangun secara luring dari data pengembangan. Setiap titik bank memuat representasi vektor suatu pertanyaan pengembangan dan skor hibrida tertinggi dari kandidat tidak valid yang telah diaudit untuk pertanyaan tersebut. Skor ini disebut *hardest-audited-invalid score*. Istilah tersebut merujuk pada nilai maksimum dalam cakupan kandidat yang telah diaudit, sehingga tidak dianggap sebagai nilai maksimum seluruh kandidat tidak valid dalam korpus. Ketika pertanyaan baru diterima, sistem membentuk lingkungan semantik (*semantic neighborhood*) dari pertanyaan-pertanyaan kalibrasi yang berdekatan, kemudian menggunakan kuantil empiris skor tidak valid di lingkungan tersebut sebagai ambang penerimaan respons.

Bentuk lingkungan semantik yang direncanakan untuk dibandingkan meliputi *k-nearest neighbors* (kNN) tanpa penyaring jarak (N1), kNN dengan *far-query gate* (N1-G), serta lingkungan berbasis batas kemiripan atau *radius* (N2). Kuantil negatif global (B2) digunakan sebagai kontrol untuk memisahkan pengaruh lokalitas dari penggunaan kuantil itu sendiri. Penelitian juga membandingkan metode tersebut dengan ambang statis terkalibrasi pada kandidat Top-1 yang sama. Aturan penggunaan kuantil global sebagai mekanisme pengganti (*fallback*) ketika syarat lingkungan lokal tidak terpenuhi menjadi bagian dari rancangan

yang turut dievaluasi. Perbandingan ini diperlukan untuk mengetahui apakah informasi lokal memberikan manfaat tambahan dibandingkan kalibrasi global dan ambang statis yang dikalibrasi dengan kendala risiko sepadan.

Penggunaan informasi lokal dan kuantil memperoleh landasan konseptual dari kajian kalibrasi lokal. *Localized conformal prediction* menekankan informasi kalibrasi di sekitar titik uji (Guan, 2023). Kajian *neighborhood conformal prediction* memanfaatkan kedekatan representasi untuk menentukan lingkungan kalibrasi (Ghosh et al., 2023), sementara kajian pembobotan lokal membahas hubungan antara lokalitas dan jaminan prediksi (Hore & Barber, 2025). Meskipun memberikan motivasi bagi rancangan LNQ, penelitian ini menggunakan skor ketidakvalidan penggunaan ulang respons dan tujuan evaluasi *cache* yang berbeda. Oleh sebab itu, penggunaan kuantil lokal tidak dengan sendirinya memberikan jaminan cakupan konformal atau jaminan formal *false positive rate* (FPR) yang bebas distribusi.

Evaluasi kebijakan penerimaan juga perlu memperhitungkan keseimbangan antara ketepatan dan pemanfaatan *cache*. Kajian mengenai kesenjangan operasional *semantic caching* menekankan bahwa kualitas pemeringkatan belum tentu mencerminkan manfaat sistem pada ambang penerimaan yang digunakan saat operasi (Baral et al., 2026). Selain itu, SCALM menunjukkan pentingnya memperhatikan penghematan token dalam evaluasi *cache*, karena setiap pertanyaan dapat memiliki kebutuhan pemrosesan yang berbeda (Li et al., 2024). Dalam penelitian ini, penerimaan kandidat tidak valid diperlakukan sebagai kesalahan penggunaan ulang (*false positive reuse*), sehingga tidak diberi kredit sebagai penghematan token yang valid. Penilaian direncanakan mencakup FPR, presisi *cache*, tingkat penggunaan ulang yang valid, konsumsi token, latensi, dan kualitas respons secara menyeluruh. Tambahan waktu komputasi untuk pencarian lingkungan serta perhitungan kuantil juga diukur agar manfaat efisiensi dapat dinilai terhadap biayanya.

Agar perbandingan dapat dipertanggungjawabkan, pembentukan bank kalibrasi dan pemilihan parameter dilakukan menggunakan data pengembangan, sedangkan data uji terpisah digunakan setelah konfigurasi dibekukan. Pemisahan ini penting karena pemilihan model atau konfigurasi berdasarkan kinerja pada data yang sama dapat menimbulkan optimisme pada estimasi kinerja (Rink & Brannath, 2025). Kelompok pertanyaan yang saling berkaitan, seperti parafrasa dan pasangan dengan perbedaan kondisi minimal, perlu diperhatikan dalam pembagian data serta analisis ketidakpastian. Dengan rancangan tersebut, penelitian ini diarahkan untuk menghasilkan bukti empiris mengenai manfaat dan keterbatasan ambang berbasis LNQ dalam menekan penggunaan ulang respons yang keliru sambil mempertahankan penggunaan ulang yang valid. Keunggulan metode lokal atas pembanding tetap ditentukan oleh hasil pengujian, termasuk apabila tidak ditemukan konfigurasi yang memenuhi sasaran risiko dan manfaat yang ditetapkan.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membangun bank kalibrasi dari *hardest-audited-invalid score* dan merancang ambang penerimaan berbasis LNQ untuk setiap pertanyaan masuk pada *hybrid semantic cache*?
2. Bagaimana menentukan parameter pencarian, kuantil, lingkungan semantik, *gate*, dan *fallback*, serta sasaran FPR dan presisi *cache* menggunakan data pengembangan tanpa kebocoran informasi dari data uji?
3. Bagaimana perbandingan LNQ dengan lingkungan N1, N1-G, dan N2 terhadap ambang statis terkalibrasi serta kuantil negatif global dalam menyeimbangkan kesalahan penggunaan ulang dan penggunaan ulang yang valid pada kandidat Top-1 yang sama?
4. Seberapa besar manfaat efisiensi token dan latensi serta tambahan biaya komputasi metode yang diusulkan, dan bagaimana kualitas responsnya dibandingkan dengan pemrosesan RAG/LLM tanpa *response cache*?

1.3 Batasan Masalah

Untuk menjaga keterarahan penelitian dan memisahkan pengaruh kebijakan ambang dari komponen sistem lainnya, ruang lingkup penelitian dibatasi sebagai berikut:

1. Penelitian dilakukan pada simulasi layanan pelanggan pembayaran digital berbahasa Indonesia. Pertanyaan yang dikaji berhubungan dengan prosedur dan pertanyaan yang sering diajukan, dengan jawaban stabil dalam satu versi basis pengetahuan. Pembatasan ini digunakan untuk memusatkan evaluasi pada validitas penggunaan ulang respons dalam konteks kebijakan yang tetap.
2. Interaksi dibatasi pada satu giliran (*single-turn*). Permintaan yang memerlukan saldo, status transaksi waktu nyata, identitas pribadi, atau sumber data dinamis tidak diperlakukan sebagai respons yang secara otomatis dapat digunakan ulang. Pemeriksaan kelayakannya dilakukan berdasarkan informasi yang tersedia saat sistem beroperasi, bukan menggunakan label kebenaran dari data evaluasi.
3. Kontribusi utama dibatasi pada pembentukan bank kalibrasi luring dan penentuan ambang penerimaan per pertanyaan masuk. Optimasi penggantian entri *cache*, pelatihan ulang LLM utama, pembelajaran ambang secara daring, dan pemodelan percakapan multigilir berada di luar fokus penelitian.
4. Seluruh metode ambang menggunakan korpus *cache*, aturan kelayakan, model representasi, serta fungsi skor hibrida yang sama dalam setiap perbandingan. Keputusan penerimaan dilakukan terhadap satu kandidat Top-1 setelah penyaringan korpus yang konsisten. Penolakan kandidat tersebut tidak dilanjutkan dengan mencoba kandidat peringkat berikutnya, agar pengaruh kebijakan ambang dapat dibandingkan pada kandidat yang identik.
5. Korpus *cache* final direncanakan dikurasi dari basis pengetahuan secara independen dari hubungan berlabel antara pertanyaan uji dan kandidat. Korpus dibekukan sebelum pertanyaan uji disusun atau dipilih. Data serta *cache* dari eksplorasi awal digunakan

untuk studi pendahuluan atau pengembangan, bukan sebagai data uji konfirmatori yang dianggap belum pernah digunakan.

6. Validitas penggunaan ulang ditentukan berdasarkan kesesuaian respons kandidat terhadap kondisi pertanyaan masuk menurut basis pengetahuan atau jawaban acuan. Pasangan pertanyaan dan kandidat merupakan unit anotasi, sedangkan unit evaluasi keputusan ambang adalah kandidat Top-1 aktual per pertanyaan. Skor kalibrasi merupakan maksimum atas kandidat tidak valid yang telah diaudit dalam cakupan pencarian yang didokumentasikan. Kandidat evaluasi tanpa label tidak dianggap tidak valid dan tidak dihilangkan tanpa pelaporan.
7. Pembentukan bank, pemilihan parameter, dan kalibrasi ambang hanya menggunakan data pengembangan sesuai pembagian kelompok yang ditetapkan. Parafrasa, turunan templat, serta pasangan pertanyaan dengan perbedaan kondisi minimal yang saling berkaitan dipertahankan dalam kelompok pembagian yang sama. Data uji terpisah digunakan setelah konfigurasi dibekukan untuk membatasi kebocoran informasi dan bias pemilihan konfigurasi.
8. Pembanding utama meliputi pemrosesan tanpa *response cache* (B0), ambang statis berdasarkan indeks ROC–Youden (B1-J), ambang statis dengan kendala risiko (B1-C), dan kuantil negatif global (B2). Bentuk lokal yang diuji meliputi N1, N1-G, dan N2. Kuantil global dengan tingkat kuantil yang sama digunakan sebagai *fallback* utama ketika syarat *gate* atau dukungan lingkungan lokal pada N1-G dan N2 tidak terpenuhi. Bank yang tidak valid menyebabkan penggunaan ulang ditolak dan permintaan diteruskan ke jalur pemrosesan lengkap.
9. Ukuran data, proporsi pembagian, perangkat implementasi, nilai parameter, dan sasaran numerik risiko belum ditetapkan sebagai hasil final dalam kerangka penelitian. Penetapannya dilakukan melalui prosedur pengembangan yang terdokumentasi sebelum pengujian akhir. Sasaran risiko dijustifikasi berdasarkan manfaat dan kerugian penggunaan ulang serta batas kesalahan operasional atau skenario risiko. Nilai contoh eksplorasi awal tidak diperlakukan sebagai parameter optimal.
10. Kesimpulan dibatasi pada domain, versi basis pengetahuan, model, data, dan protokol evaluasi yang digunakan. Efisiensi dinilai dari token dan latensi yang benar-benar diukur, termasuk tambahan biaya metode lokal. Skor kemiripan tidak dianggap sebagai probabilitas kebenaran, dan LNQ tidak diklaim memiliki jaminan formal FPR atau cakupan konformal. Penolakan seluruh kandidat tidak dianggap sebagai bukti manfaat sistem karena penggunaan ulang yang valid tetap menjadi pertimbangan.

1.4 Tujuan

Penelitian ini bertujuan merancang dan mengevaluasi ambang penerimaan adaptif berbasis LNQ pada *hybrid semantic cache* untuk mengkaji pengendalian kesalahan penggunaan ulang respons dan efisiensi inferensi LLM. Tujuan khusus penelitian yang bersesuaian dengan rumusan masalah adalah sebagai berikut:

1. Merancang dan mengembangkan *hybrid semantic cache*, bank kalibrasi luring berbasis *hardest-audited-invalid score*, serta fungsi kuantil negatif lokal untuk menghasilkan

keputusan penerimaan atau penolakan penggunaan ulang respons per pertanyaan masuk.
2. Menyusun prosedur serta menentukan parameter pencarian dan kebijakan ambang menggunakan data pengembangan, dengan sasaran FPR dan presisi *cache* yang dijustifikasi dan konfigurasi yang dibekukan sebelum pengujian akhir.
3. Membandingkan N1, N1-G, dan N2 dengan ambang statis terkalibrasi serta kuantil negatif global pada fondasi pencarian yang sama, disertai analisis ablasi untuk mengidentifikasi pengaruh lokalitas, *gate*, dan *fallback* terhadap kesalahan serta penggunaan ulang yang valid.
4. Mengukur FPR, presisi *cache*, *valid cache hit ratio* (VCHR), pemanfaatan *cache*, penghematan token yang valid, latensi, tambahan biaya komputasi, kualitas respons, serta ketidakpastian hasil pada data uji terpisah dengan pemrosesan tanpa *response cache* sebagai acuan efisiensi dan kualitas.

1.5 Manfaat

Penelitian ini diharapkan memberikan manfaat sebagai berikut:

1.5.1 Manfaat Teoritis

1. Menambah bukti empiris mengenai hubungan antara distribusi skor kandidat tidak valid pada lingkungan semantik lokal dan kinerja ambang penerimaan respons dalam *hybrid semantic cache*.
2. Memberikan pemahaman mengenai perbedaan manfaat lokalitas, mekanisme penyaring lingkungan, serta *fallback* terhadap keseimbangan antara kesalahan penggunaan ulang dan penggunaan ulang yang valid melalui perbandingan dengan kalibrasi global serta ambang statis.

1.5.2 Manfaat Praktis

1. Menyediakan rancangan dan prototipe kebijakan penerimaan respons yang dapat dijadikan acuan pengembangan *semantic cache* pada layanan pelanggan dengan jawaban stabil, disertai pencatatan keputusan dan prosedur kalibrasi yang dapat ditelusuri.
2. Menyediakan hasil pengukuran yang membantu pengembang mempertimbangkan ketepatan respons, penghematan token, latensi, dan tambahan biaya komputasi sebelum memilih konfigurasi *cache* sesuai kebutuhan layanan.

1.5.3 Manfaat Sosial

1. Memberikan dasar pertimbangan bagi pengembangan layanan informasi pembayaran digital yang lebih berhati-hati dalam menggunakan ulang jawaban, khususnya ketika pertanyaan pengguna berbeda pada kondisi yang menentukan berlakunya suatu kebijakan.
2. Mendukung upaya penyediaan layanan pelanggan yang responsif dan penggunaan sumber daya komputasi yang efisien, sepanjang hasil pengujian menunjukkan manfaat tanpa mengabaikan kualitas jawaban bagi pengguna.